

مستندسازی فرایند تمیزسازی داده - پروژه سپید لپتاپ

۱. هدف پروژه

هدف این پروژه جمع‌آوری، تمیزسازی و تحلیل داده لپتاپ‌های استوک از فروشگاه‌های آنلاین ایرانی است. خروجی نهایی یک دیتاست ساختاریافته است که امکان تحلیل ارزش خرید لپتاپ‌های استوک را فراهم می‌کند و می‌تواند پایه یک مدل کسب‌وکار برای سرمایه‌گذاری یا فروش داده باشد.

۲. منابع داده (/input_data)

داده‌های خام از ۶ فروشگاه آنلاین با استفاده از **Selenium** و **web scraping** استخراج شده و به‌صورت فایل‌های CSV در پوشه `/input_data` ذخیره شده‌اند:

فایل	فروشگاه
<code>laptoria.csv</code>	Laptoria
<code>giga.csv</code>	Giga
<code>zhinal.csv</code>	Zhinal
<code>goldkala.csv</code>	Goldkala
<code>piclap.csv</code>	Piclap
<code>tagcenter.csv</code>	Tagcenter

هر فایل CSV شامل ستون‌های خام اولیه است: مشخصات لپتاپ، پردازنده، برند، وضعیت، مانیتور، حافظه داخلی، رم، گرافیک، قیمت، سایت، لینک.

نکته: فایل `torob.csv` از طریق اسکریپت مجزا (`torob_main.py`) با منطق استخراج متفاوت پردازش می‌شود.

۳. ساختار برنامه تمیزسازی (/cleaning_prg)

۳.۱ اسکریپت اصلی — `main.py`

فایل `main.py` نقش **Orchestrator** دارد؛ یعنی تمام مراحل تمیزسازی را به ترتیب فراخوانی می‌کند:

```
brand_ext() → cpu_ext() → ssd_ext() → ram_ext()
→ gpu_ext() → monitor_ext() → price_ext() → link_ext()
```

برای هر فروشگاه یک فایل `main.py` مجزا اجرا می‌شود که مسیر ورودی و خروجی آن متفاوت است. خروجی هر اجرا یک فایل `xlsx.*` در پوشه `/clean_data` است.

۳.۲ ماژول‌های پارسر (/parsers)

هر ستون داده توسط یک فایل پارسر مستقل پردازش می‌شود:

فایل	وظیفه	ستون‌های خروجی
brand.py	استخراج و استانداردسازی برند	brand
cpu.py	پارس اطلاعات پردازنده	cpu_brand, cpu_family, cpu_series, cpu_model, cpu_generation, cpu_full_spec, cpu_class
gpu.py	پارس اطلاعات گرافیک	gpu_brand, gpu_family, gpu_series, gpu_type, gpu_model, gpu_vram, gpu_vram_unit, gpu_full_spec
monitor.py	پارس اطلاعات مانیتور	monitor_screen_size, size_unit, monitor_resolution, monitor_refresh_rate, refrate_unit, monitor_panel_type, monitor_touch
ram.py	استخراج حجم رم	ram_raw_value, ram_unit
ssd.py	استخراج حجم SSD	ssd_raw_value, ssd_unit
price.py	استخراج قیمت	price_raw, price_unit

۳.۳ فایل‌های قوانین (/rules)

پارسرهای پیچیده (CPU، GPU، Monitor، Brand) از فایل‌های JSON برای تعریف الگوهای تشخیص استفاده می‌کنند. این جداسازی امکان افزودن قوانین جدید بدون تغییر کد را فراهم می‌کند:

فایل	کاربرد
cpu_rules.json	الگوهای regex و متادیتای تمام خانواده‌های CPU (Intel, AMD, Apple, Qualcomm)
gpu_rules.json	الگوهای تشخیص GPU به همراه نوع (Dedicated/Integrated) و وجود VRAM
monitor_rules.json	الگوهای تشخیص سایز، رزولوشن، نرخ تازه‌سازی، نوع پنل و لمسی بودن
brand_rules.json	مپینگ نوشتارهای مختلف فارسی/انگلیسی برند به نام استاندارد

۳.۴ ابزارهای کمکی (/utils)

فایل	وظیفه
normalize.py	نرمال‌سازی متن ورودی قبل از پارس: تبدیل اعداد فارسی به انگلیسی، حذف کاراکترهای اضافه، lowercase، و توابع dedup
merger.py	ادغام فایل‌های xlsx پاک‌شده در فایل نهایی

۳.۵ گزارش‌دهی (/empty_reporter)

فایل	وظیفه
reporter.py	اسکن فایل‌های خروجی و شناسایی سلول‌های خالی
empty_cells_report.txt	گزارش تعداد و محل سلول‌های خالی به تفکیک ستون
extracted_values.txt	نمونه مقادیر استخراج‌شده برای بررسی کیفیت

۴. فرایند تمیزسازی — گام به گام

گام ۱: نرمال‌سازی (utils/normalize.py)

قبل از هر پارسی، متن خام نرمال‌سازی می‌شود:

- تبدیل اعداد فارسی/عربی به انگلیسی
- حذف کاراکترهای کنترلی و فضاها
- حذف تکرار با تابع dedup
- کردن متن lowercase

گام ۲: استخراج برند

متن ستون «برند» با فایل brand_rules.json مقایسه می‌شود. ابتدا جستجوی مستقیم (exact match)، سپس جستجوی جزئی (partial match) انجام می‌شود. اگر هیچ‌کدام نتیجه نداد، مقدار اصلی با title-case برگردانده می‌شود.

گام ۳: استخراج CPU

ستون «پردازنده» پس از نرمال‌سازی با الگوهای cpu_rules.json تطبیق داده می‌شود. برای هر CPU اطلاعات زیر استخراج می‌شود:

- برند، خانواده، سری، مدل دقیق
- نسل (با روش‌های مختلف: intel_core, intel_ultra, amd_ryzen, snapdragon, prefix_map)
- کلاس عملکردی (entry, mainstream, high_performance, enthusiast)

اگر ستون پردازنده خالی بود، تلاش می‌شود از ستون مشخصات کامل استخراج شود.

گام ۴: استخراج RAM و SSD

متن نرمال‌شده با regex ساده پارس می‌شود. برای SSD، پیشنهادهای DDR/LPDDR که به اشتباه در ستون SSD ثبت شده‌اند ابتدا حذف می‌شوند. واحدها (gb, tb) تشخیص داده شده و مقدار خام عددی جداگانه ذخیره می‌شود.

گام ۵: استخراج GPU

ستون «گرافیک» با الگوهای `gpu_rules.json` تطبیق داده می‌شود. به دلیل تنوع بالا، قوانین به ترتیب اولویت از خاص به عام چیده شده‌اند (مثلاً RTX 4090 قبل از GeForce Generic). VRAM نیز با `regex` جداگانه استخراج می‌شود.

گام ۶: استخراج مانیتور

پنج ویژگی مانیتور به صورت مستقل استخراج می‌شوند: سایز (با `fallback` محاسبه از PPI)، رزولوشن (`label` استاندارد مثل FHD/QHD/4K)، نرخ تازه‌سازی (با مقدار پیش‌فرض ۶۰)، نوع پنل، و لمسی بودن.

گام ۷: استخراج قیمت

قیمت با `regex` ساده استخراج می‌شود. واحد (IRR یا IRT) جداگانه ذخیره می‌شود.

گام ۸: ذخیره خروجی

دیتافریم تمیزشده به فایل `*.xlsx` در پوشه `/clean_data` ذخیره می‌شود.

۵. ادغام نهایی (utils/merger.py)

پس از اجرای `main.py` برای تمام فروشگاه‌ها، اسکریپت `merger` تمام فایل‌های `xlsx` را با هم ادغام می‌کند:

- ستون `Origin` (نام فروشگاه) به عنوان اولین ستون اضافه می‌شود
- ایندکس‌گذاری مجدد از صفر انجام می‌شود
- تمام سلول‌های خالی به `pd.NA` استاندارد تبدیل می‌شوند
- خروجی نهایی `final_6.xlsx` در `/clean_data` ذخیره می‌شود

۶. ستون‌های دیتاست نهایی

ستون	نوع	توضیح
Origin	string	نام فروشگاه منبع
brand	string	برند لپ‌تاپ (استاندارد انگلیسی)
cpu_brand	string	برند پردازنده
cpu_family	string	خانواده پردازنده
cpu_series	string	سری پردازنده
cpu_model	string	مدل دقیق پردازنده
cpu_generation	integer	نسل پردازنده
cpu_full_spec	string	مشخصات کامل پردازنده
cpu_class	string	کلاس عملکردی
ssd_raw_value	integer	حجم SSD (گیگابایت)
ssd_unit	string	واحد SSD

ستون	نوع	توضیح
ram_raw_value	integer	حجم RAM (گیگابایت)
ram_unit	string	واحد RAM
gpu_brand	string	برند گرافیک
gpu_family	string	خانواده گرافیک
gpu_series	string	سری گرافیک
gpu_type	string	نوع گرافیک (Dedicated/Integrated)
gpu_model	string	مدل گرافیک
gpu_vram	integer	حافظه اختصاصی گرافیک
gpu_vram_unit	string	واحد VRAM
gpu_full_spec	string	مشخصات کامل گرافیک
monitor_screen_size	float	سایز صفحه (اینچ)
size_unit	string	واحد سایز
monitor_resolution	string	رزولوشن (.../FHD/QHD/4K)
monitor_refresh_rate	integer	نرخ تازه‌سازی (Hz)
refrate_unit	string	واحد نرخ تازه‌سازی
monitor_panel_type	string	نوع پنل (IPS/OLED/VA/TN)
monitor_touch	boolean	لمسی بودن صفحه
price_raw	integer	قیمت خام عددی
price_unit	string	واحد قیمت (IRR/IRT)
product_link	string	لینک محصول

۷. چالش‌های شناخته‌شده و راه‌حل‌ها

چالش	راه‌حل
تنوع نوشتاری برندها به فارسی	فایل brand_rules.json با variant های مختلف
SSD در ستون DDR	حذف پیشوندهای DDR/LPDDR قبل از پارس
("GB Dedicated" مثل 8") بدون مدل مشخص GPU	با اولویت پایین fallback های rule
GPU های ناشناخته (Adreno، RX Vega)	افزودن rule های جدید به gpu_rules.json
ستون پردازنده خالی	به ستون مشخصات کامل fallback
ناهمخوانی فرمت بین فروشگاه‌ها	نرمال‌سازی در utils/normalize.py

۸. مرحله بعدی — تحلیل داده

پس از تولید `final_6.xlsx`، مرحله تحلیل با **Pandas** آغاز می‌شود. هدف اصلی تعیین ارزش خرید هر لپ‌تاپ استوک بر اساس مشخصات سخت‌افزاری و قیمت آن است. چارچوب دقیق تحلیل در مرحله بعد تدوین خواهد شد.